实验二: SPARK 基础编程方法

胡嘉鑫 102102145

2023年10月24日

目录

2 实验平台									2											
										2										
3	实验步骤														2					
	3.1	数据去	重																	2
		3.1.1	Problem	Descriptio	n.															2
		3.1.2	Code																	3
		3.1.3	Result .																	4
	3.2	求平均	值																	4
		3.2.1	Problem	Descriptio	n.															4
		3.2.2	Code																	5
		3.2.3	Result .																	6
	3.3	人数,	身高统计																	7
		3.3.1	Problem	Descriptio	n .															7
		3.3.2	Code																	7
		3.3.3	Result .																	9
	3.4	用户关	系统计.																	9
		3.4.1	Problem	Descriptio	n .															9
		3.4.2	Code																	9
		3.4.3	Result .																	11
4	出现	的问题。	及其解决 力	方案																11

1 实验目的

- 理解 SPARK 工作流程;
- 掌握 SPARK 基础编程方法.

2 实验平台

- OS: Linux
- Hadoop v3.1.3
- JDK v1.8
- Spark: 3.4.0

3 实验步骤

3.1 数据去重

3.1.1 Problem Description

描述: 编写独立应用程序实现数据去重, 对于两个输入文件 A 和 B, 编写 Spark 独立应用程序(推荐使用 Scala 语言),对两个文件进行合并,并剔除其中重复的内容,得到一个新的文件 C。(文件 A, B 如下).

Input(输入文件 A):

- $20170101 \ {\rm x}$
- $20170102 \ {\rm y}$
- $20170103 \ {\rm x}$
- 20170104 y
- $20170105 \ {\rm z}$
- 20170106 z

Input(输入文件 B):

- 20170101 y
- 20170102 y
- 20170103 x
- 20170104 z
- 20170105 y

Expected output:

```
20170101 x
20170101 y
20170102 y
20170103 x
20170104 y
20170105 y
20170105 z
20170106 z
```

3.1.2 Code

```
package net.homework
import org.apache.spark.SparkConf
import org.apache.spark.SparkContext
import org.apache.spark.SparkContext._
import java.nio.file.Paths
object App {
  def main(args : Array[String]) : Unit = {
    val cwd = Paths.get("").toAbsolutePath.toString
    val inputPath = "file://" + cwd + "/input"
    val outputPath = "file://" + cwd + "/output"
    val inputFile0 = inputPath + "/A.txt"
    val inputFile1 = inputPath + "/B.txt"
    val conf = new SparkConf().setMaster("local").setAppName("pro1")
    val sc = new SparkContext(conf)
    val input0 = sc.textFile(inputFile0)
    val input1 = sc.textFile(inputFile1)
    val unionRes = input0.union(input1)
```

```
val res = unionRes.distinct.sortBy(_.split(" ")(0))
  res.saveAsTextFile(outputPath)
}
```

3.1.3 Result

图 1: 数据去重

3.2 求平均值

3.2.1 Problem Description

描述: 每个输入文件表示班级学生某个学科的成绩,每行内仅由两个字段组成,第一个是学生名字,第二个是学生的成绩;编写 Spark 独立应用程序(推荐使用 Scala 语言)求出所有学生的平均成绩,并输入到一个新文件中。(各个科目的程序文件如下)

Algorithm 成绩:

小明 92

小红 87

小新 82

小丽 90

Database 成绩:

小明 95

小红 81

```
小新 89
小丽 85
   Python 成绩:
小明 82
小红 83
小新 94
小丽 91
   平均成绩如下:
(小红,83.67)
(小新,88.33)
(小明,89.67)
(小丽,88.67)
3.2.2 Code
  package net.homework
  import org.apache.spark.SparkConf
  import org.apache.spark.SparkContext
  import org.apache.spark.SparkContext._
  import java.nio.file.Paths
  import java.io.File
  object App {
    def main(args : Array[String]) : Unit = {
      val cwd = Paths.get("").toAbsolutePath.toString
      val inputPath = "file://" + cwd + "/input"
      val outputPath = "file://" + cwd + "/output"
      val conf = new SparkConf().setMaster("local").setAppName("pro2")
      val sc = new SparkContext(conf)
      val textData = sc.wholeTextFiles(inputPath)
      \verb|val textContent = textData.map(\_._2).flatMap(\_.split("\n"))|\\
```

```
val dir = new File(s"${cwd}/input")
var subjectCount : Double = 1
if (dir.isDirectory) {
    subjectCount = dir.listFiles().count(_.isFile)
}

val res = textContent.map(
    x => (x.split("\t")(0), x.split("\t")(1).toInt)
).reduceByKey(
    (val1, val2) => val1 + val2
).map(
    x => (x._1, f"${x._2/subjectCount}%.2f")
)

res.saveAsTextFile(outputPath)
}
```

3.2.3 Result

图 2: 求平均值

3.3 人数,身高统计

3.3.1 Problem Description

描述:对于文件 people.txt,该文件包含了序号、性别和身高三个列,编写 Spark 应用程序,计算得到男性总数、女性总数、男性最高身高、女性最高身高、男性最低身高、女性最低身高、女性平均升高、女性平均身高。

文件形式如下:

0 F 168 1 F 141

2 M 184

3 F 186

3.3.2 Code

```
package net.homework
import org.apache.spark.SparkConf
import org.apache.spark.SparkContext
import org.apache.spark.SparkContext._
import java.nio.file.Paths
import java.io.File
object App {
  def main(args : Array[String]) : Unit = {
    val cwd = Paths.get("").toAbsolutePath.toString
    val inputPath = "file://" + cwd + "/input"
    val conf = new SparkConf().setMaster("local").setAppName("pro3")
    val sc = new SparkContext(conf)
    val textData = sc.wholeTextFiles(inputPath)
    val textContent = textData.map(_._2).flatMap(_.split("\n"))
    val people = textContent.map(
      x => {
```

```
val arr = x.split("\t")
       (arr(2).toDouble, arr(1))
     }
   )
   val male = people.filter(x => x._2 == "M").map(_._1)
   val female = people.filter(x => x._2 == "F").map(_._1)
   val numOfMale = male.count
   val numOfFemale = female.count
   val maxHeightOfMale = male.max
   val maxHeightOfFemale = female.max
   val minHeightOfMale = male.min
   val minHeightOfFemale = female.min
   val avgHeightOfMale = male.reduce(
     (val1, val2) => val1 + val2
   ) / numOfMale
   val avgHeightOfFemale = female.reduce(
     (val1, val2) => val1 + val2
   ) / numOfFemale
   println(s"(男性总数,女性总数): ($numOfMale, $numOfFemale)")
   println(s"(男性最高身高,女性最高身高): ($maxHeightOfMale, $maxHeightOfFemale)")
   println(s"(男性最低身高,女性最低身高): ($minHeightOfMale, $minHeightOfFemale)")
   println(s"(男性平均身高,女性平均身高): ($avgHeightOfMale, $avgHeightOfFemale)")
 }
}
```

3.3.3 Result

图 3: 人数, 身高统计

3.4 用户关系统计

3.4.1 Problem Description

描述: 对于文件 relationship.txt,数据形式示例如下: A < B, C, D, F, E, O,表示用户 B, C, D, F, E, O关注了 A, 现要求分别计算每个用户被关注的数量以及每个用户关注的数量。

3.4.2 Code

```
import org.apache.spark.SparkConf
import org.apache.spark.SparkContext
import org.apache.spark.SparkContext._
import java.nio.file.Paths

object App {
  def main(args : Array[String]) : Unit = {
    val cwd = Paths.get("").toAbsolutePath.toString
```

```
val inputPath = "file://" + cwd + "/input"
    val outputPath = "file://" + cwd + "/output"
    val conf = new SparkConf().setMaster("local").setAppName("pro4")
    val sc = new SparkContext(conf)
   val textData = sc.wholeTextFiles(inputPath)
   val textContent = textData.map(_._2).flatMap(_.split("\n"))
   val res = textContent.map(
     x => {
       val arr = x.split("<")</pre>
        (arr(0), arr(1).split(","))
    ).flatMap(
      x => {
        var ret = List((x._1, (x._2.length, 0)))
        for (fan <- x._2) {
          ret = (fan, (0, 1)) +: ret
        }
        ret
    }).reduceByKey(
      (val1, val2) => (val1._1 + val2._1, val1._2 + val2._2)
    ).map(
      x \Rightarrow (x._1, x._2._1, x._2._2)
    ).sortBy(_._1)
   res.saveAsTextFile(outputPath)
 }
}
```

3.4.3 Result

图 4: 用户关系统计

4 出现的问题及其解决方案

没有问题.